Pipidu Library Agent: informe técnico

Trabajo Práctico Integrador, AI Engineering (UCSE, Ingeniería en Informática, 5.º año)

1. Resumen

Pipidu Library Agent es un agente de IA para una biblioteca universitaria. Recibe consultas en lenguaje natural (castellano o inglés) y las resuelve a partir de dos fuentes: una **base de datos relacional** (libros, autores, socios y préstamos) y un **repositorio de documentos PDF** consultado con RAG (reglamento, políticas y reseñas). El agente decide en cada consulta qué fuente usar, o si usa ambas, e informa de dónde sale la respuesta o declara que no hay información suficiente.

El sistema cumple los cuatro criterios de aprobación del enunciado y tres de los cinco criterios de promoción:

Criterio	Cómo se cumple
Modelo relacional, 5 tablas o más, más de 15 registros por tabla	7 tablas del dominio con entre 18 y 95 filas cada una (sección 2)
El agente interpreta lenguaje natural y responde con la base	Text-to-SQL con validación estática y rol de solo lectura (secciones 3 y 4)
RAG sobre 2 PDF como mínimo	6 PDF, 44 fragmentos, búsqueda vectorial con pgvector
Código documentado y reproducible	`README.md` con un único comando de arranque (`docker compose up -d --build --wait`)
Promoción: framework agéntico	Smolagents (`ToolCallingAgent`)
Promoción: interfaz gráfica	SPA propia en React con progreso en vivo, fuente y evidencia
Promoción: SDD	OpenSpec con cuatro changes, constitución, especificaciones y registro de decisiones

No se despliega en la nube ni se integra LangSmith: el sistema corre en entorno local (decisión D81), y la trazabilidad propia vive en la tabla `agent_runs`.

2. Modelo de datos

2.1 Dominio y diseño

El dominio es una biblioteca universitaria. El esquema (`db/schema.sql`) tiene **siete tablas del dominio**, dos tablas para el repositorio documental y una vista:

```
autores ──< libros_autores >── libros >── editoriales
                                  │
                                  └──>─ categorias
socios ──< prestamos >── libros
documentos ──< documentos_chunks (embedding vector(768))
v_prestamos_estado (vista sobre prestamos)       agent_runs (trazabilidad)
```

Tabla	Filas	Contenido y restricciones principales
`libros`	70	Título, ISBN único, editorial, categoría, año (CHECK 1400 a 2100), ejemplares totales y disponibles (CHECK `0 <= disponibles <= totales`)
`autores`	57	Nombre, apellido, nacionalidad; único por (nombre, apellido)
`editoriales`	28	Nombre y país
`categorias`	18	Nombre y descripción
`libros_autores`	95	Tabla puente N:M, clave primaria compuesta, columna `orden`
`socios`	20	Legajo único, `tipo_socio` (CHECK `alumno` o `docente`)

Tabla	Filas	Contenido y restricciones principales
`prestamos`	28	Fechas de préstamo, devolución prevista y real, `estado` (CHECK `activo` o `devuelto`)
`documentos` y `documentos_chunks`	6 y 44	Repositorio RAG: un registro por PDF y un fragmento por fila, con `embedding vector(768)`

Todas las tablas del dominio superan el mínimo de 15 registros que pide el enunciado. Un test (`tests/test_seed_contract.py`) lo verifica contra la base real.

2.2 Decisiones de diseño del modelo

- **Autores en tabla puente (D64).** Un libro puede tener varios autores, por eso no existe `libros.autor_id`: la relación N:M se resuelve con `libros_autores`.
- **El vencimiento no se almacena (D7).** `prestamos.estado` solo vale `activo` o `devuelto`, ligado por un CHECK a `fecha_devolucion_real` (`devuelto` si y solo si hay fecha real). El estado `vencido` se calcula en la vista `v_prestamos_estado`, que expone `estado_calculado` y `dias_atraso`. Un valor almacenado se desactualizaría cada día; la vista no.
- **Integridad en la base, no en el código.** Los CHECK, las claves foráneas (`ON DELETE RESTRICT` en el dominio, `CASCADE` en la tabla puente y en los fragmentos) y los índices por clave foránea hacen que los datos inválidos no entren, sin depender del agente.
- **Un solo motor para datos y vectores (D13).** pgvector corre sobre el mismo PostgreSQL. El índice vectorial es HNSW con distancia coseno (`vector_cosine_ops`).
- **Roles con mínimo privilegio (D14, D63).** El agente se conecta como `agent_ro`, que solo hace `SELECT` sobre los objetos permitidos. El registro de trazabilidad lo escribe otro rol, `agent_logger`, que solo puede hacer `INSERT` sobre `agent_runs`, y que `agent_ro` no puede leer.

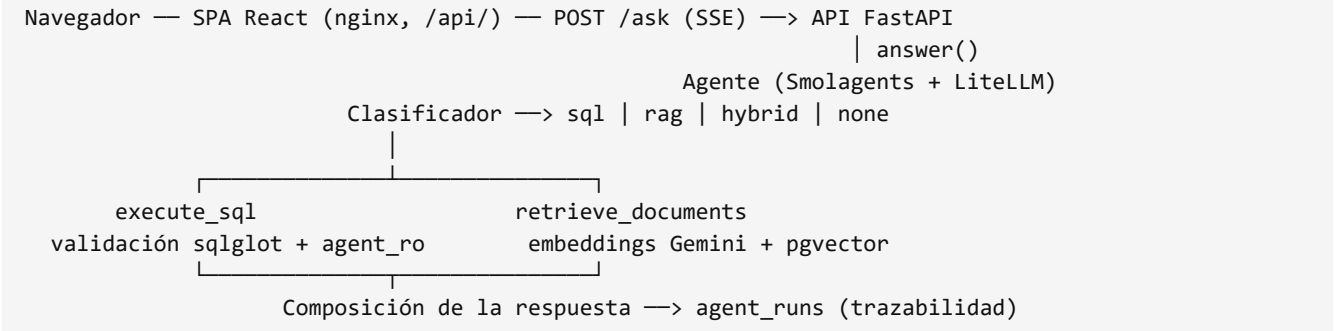
2.3 Datos

El catálogo es real: títulos, autores, editoriales e ISBN fueron verificados en Open Library (70 libros con ISBN-13 de dígito verificador válido). Los socios y los préstamos son sintéticos y sus fechas son relativas a `CURRENT_DATE`, de modo que siempre hay préstamos activos y vencidos. El seed completo es `db/seed.sql`; `db/dev_seed.sql` es un seed mínimo para las pruebas de integración.

Los **seis PDF** (`rag/documents/pdf/`) se generan desde Markdown versionado (`rag/documents/*.md`): `reglamento_biblioteca`, `politicas_universidad`, `resenas_cien_anios_de_soledad`, `resenas_clean_code`, `resenas_tolkien` y `resenas_empyrean`. Se generaron a propósito para que cada pregunta del conjunto de prueba tenga una respuesta verificable (D19).

3. Arquitectura del agente

3.1 Vista general



Se levanta con Docker Compose: `db` (PostgreSQL con pgvector), `ingest` (una sola vez, carga los PDF), `api` (puerto 8080) y `web` (puerto 3000). El modelo es Gemini (`gemini-3.1-flash-lite`) por API; los embeddings son `gemini-embedding-001` con 768 dimensiones (D5).

3.2 Flujo de una consulta

1. **Entrada.** `POST /ask` recibe la pregunta; una consulta vacía devuelve 422 sin abrir el flujo. La respuesta es un flujo de eventos SSE: `start`, `classified`, `tool_call`, `tool_result`, `step`, `composing`, `heartbeat` (cada 5 s), `result` y, ante una falla inesperada, `error` (D75).
2. **Clasificación antes de cualquier herramienta (D3).** Una llamada al modelo con salida estructurada obligatoria devuelve la fuente (`sql`, `rag`, `hybrid` o `none`), el idioma y si la consulta pide escribir datos. La clasificación se emite primero, de modo que el agente solo recibe las herramientas de la fuente elegida.
3. **Pedidos de escritura.** Si la consulta pide crear, modificar o borrar datos, no se ejecuta ninguna herramienta ni se llama al modelo para redactar: el agente responde con un mensaje fijo, porque es de solo lectura.
4. **Ejecución.** El agente (`ToolCallingAgent`, D2) usa `execute_sql`, `retrieve_documents` o ambas. En un híbrido consulta primero la base, luego los documentos y recién después concluye, separando el hecho verificado de la conclusión.
5. **Composición.** El agente redacta en el idioma de la pregunta. La fuente nunca va dentro del texto: viaja aparte en `sources`, y la evidencia (sentencia SQL, filas, fragmentos con documento y ubicación) en `evidence` (D84).
6. **Ausencia de información.** Si ninguna fuente tiene la respuesta, el agente lo declara en lugar de inventar (`answer_kind = no_coverage`).
7. **Trazabilidad.** Cada consulta queda en `agent_runs` con la clasificación, las herramientas, la sentencia generada y la ejecutada, los fragmentos, cada intento, el modelo, la latencia y el estado.

3.3 Herramienta SQL

El contrato está invertido (D1): **el agente genera el SQL y la herramienta solo lo valida y lo ejecuta**. Así la herramienta se prueba sin credenciales de API y cada sentencia queda atribuida al modelo. La ejecución tiene `statement_timeout` de 10 s, devuelve a lo sumo 50 filas y permite hasta 2 intentos de regeneración si la validación rechaza la sentencia (D8).

3.4 Herramienta RAG

La ingesta divide cada documento por sección (`##`): un fragmento por artículo o paso, con el título del documento antepuesto (D10). La clave de idempotencia es el hash `sha256` del PDF y la unicidad `(documento, posición)` (D11), de modo que reingestar no duplica. En consulta, se calculan los embeddings de la pregunta y se recuperan los 5 fragmentos más similares por coseno; si el mejor no supera el umbral de **0,64**, la herramienta informa que no hay resultados relevantes y el agente no responde con conocimiento propio (D12).

3.5 Interfaz web

La SPA (`web/`: React 19, TypeScript, Vite, Tailwind y shadcn/ui) es un cliente de la API. Muestra el progreso en vivo como una línea de tiempo («Clasificada: corresponde consultar la base de datos», «Devolvió 2 filas», «Armando la respuesta»), la respuesta en Markdown con la fuente como insignia, y un panel plegable «Ver evidencia» con la sentencia SQL, la tabla de filas y los fragmentos citados. Permite cancelar una consulta en curso y reintentar ante fallas de conexión. Distingue visualmente las respuestas normales, la ausencia de información y los errores. En Docker, nginx sirve la SPA y reenvía `/api/` a la API sin buffering, para que el flujo llegue en vivo (D93).

4. Seguridad de la generación de SQL

El SQL lo escribe un modelo de lenguaje, así que se trata como entrada no confiable. Hay cuatro capas, de modo que ninguna falla individual abra una escritura o una fuga:

1. **Prompt.** Restringe la generación a un único `SELECT` sobre el esquema documentado, con la semántica temporal (cuatrimestre, zona horaria) resuelta desde la configuración (D6).
2. **Validación estática con `sqlglot` (D4).** Se parsea la sentencia con modo estricto en lugar de usar expresiones regulares, que no distinguen CTE, subconsultas ni identificadores entre comillas. Se rechaza todo lo que no sea lectura (`INSERT`, `UPDATE`, `DELETE`, `DROP`, `COPY`, `FOR UPDATE`, escrituras dentro de una CTE), los puntos y coma y los comentarios; se resuelven tablas y columnas **por ámbito** contra una lista blanca (D38); `SELECT *` se expande a las columnas permitidas, para que no se alcance una columna no documentada; las funciones permitidas son una lista cerrada (se rechazan `pg_sleep`, `pg_read_file`, `dblink`, etc.); y se limita la complejidad (sin `WITH RECURSIVE` y con un tope de tablas por consulta).
3. **Rol `agent_ro`.** Aunque la validación fallara, la base solo concede `SELECT` sobre los objetos permitidos, con `statement_timeout` y `search_path` restringido (D14). El repositorio documental queda fuera del alcance del SQL (D21).
4. **Falla cerrada.** Una sentencia rechazada nunca abre conexión; cualquier error interno de la validación se informa como rechazo.

La sentencia que se registra y se muestra al usuario es la **normalizada**, la que realmente se ejecutó; la original del modelo se conserva para la auditoría.

5. Decisiones técnicas principales

El registro completo, con fecha, alternativa descartada y motivo de cada decisión, está en `TP/CHANGELOG.md`. Las más relevantes:

Decisión	Alternativa descartada	Motivo
D1 El agente genera el SQL; la herramienta valida y ejecuta	La herramienta recibe la pregunta y llama al modelo	Se puede probar sin credenciales y el SQL queda atribuido
D2 `ToolCallingAgent`	`CodeAgent`	`CodeAgent` exige un ejecutor de código y agrega una superficie de ejecución que el agente no necesita
D3 Clasificación con salida estructurada, antes de las herramientas	Instrucción en texto libre	La fuente es verificable y el agente solo recibe las herramientas que corresponden
D4 Validación con `sqlglot`	Expresiones regulares	Distinguen mal CTE, subconsultas e identificadores
D7 Vencimiento calculado en una vista	Guardar el estado `vencido`	Un valor almacenado se desactualiza
D9 `psycopg2` directo	SQLAlchemy	Hay un único `SELECT` dinámico; un ORM entorpece la validación estática y el control del timeout
D10 Fragmentos por sección	Cortes de largo fijo	Un fragmento por artículo permite citar la ubicación
D12 Umbral 0,64 y top-k 5	Valor arbitrario sin medir	Calibrado con 21 casos sobre los documentos reales
D14 Rol de solo lectura propio	`SET ROLE` desde un usuario con más permisos	Defensa en profundidad
D16 Pruebas sobre clasificación, SQL y filas	Comparar la prosa	El texto del modelo no es determinista
D56 Proveedor configurable	Modelo fijo en el código	Se valida el flujo con un modelo local sin gastar cuota

Decisión	Alternativa descartada	Motivo
D77 Consultas en serie	Concurrencia sin control	Cada backend guarda una sola conexión: dos consultas simultáneas se pisarían
D80 La API es el único acceso al agente	Interfaz Streamlit en el mismo servicio	El frontend consume el agente por HTTP y la evidencia viaja en `result.evidence`
D81 Ejecución local	Despliegue en la nube	Decisión del equipo; el sistema corre con Docker
D84 La fuente nunca va en el texto	Línea «Fuente:» al pie	La interfaz ya la muestra desde `sources`; si estaba en el texto, aparecía duplicada
D93 SPA propia en su servicio, con proxy del mismo origen	Interfaz Streamlit en el servicio del agente (D80)	En Docker la web llega a la API por un proxy del mismo origen, sin CORS, y cubre el criterio de promoción «Interfaz gráfica»

6. Pruebas y evidencias

6.1 Pruebas automáticas

La suite tiene **460 pruebas** que corren sin base, sin credenciales y sin modelo (`pytest -q`); además hay pruebas de integración y con el modelo real que se ejecutan aparte. Cubren: la validación de SQL (más de 160 casos, entre sentencias que deben rechazarse y que deben aceptarse), la herramienta SQL, la recuperación, el clasificador, el orquestador, los contratos, la trazabilidad, la API (flujo SSE, cancelación, CORS) y la imagen de Docker. El frontend tiene sus propias pruebas con Vitest. Se agregan `ruff` para el estilo y `openspec validate --all --strict` para las especificaciones.

Las **pruebas de sanitización** son casos adversos con rechazo sin ejecución contra la base: `DELETE` y `DROP`, sentencias apiladas, comentarios, tablas fuera de la lista blanca (`agent_runs`, `pg_catalog`), columnas no documentadas, funciones de efecto (`pg_sleep`, `pg_read_file`, `dblink`), `FOR UPDATE`, CTE homónimas que ocultan una tabla prohibida, escrituras dentro de una CTE y cadenas mal formadas. Un mismo conjunto verifica que las consultas legítimas, incluidas las que usan `CASE`, `EXISTS` o `string_agg`, sí se acepten.

6.2 Conjunto de pruebas del agente (golden set)

Son 13 preguntas con respuesta esperada (5 SQL, 4 RAG, 3 híbridas y 1 sin cobertura) más 2 en inglés. Las afirmaciones van sobre la clasificación, el SQL y las filas, no sobre la prosa (D16). El criterio de aceptación es acertar **al menos 11 de 13** clasificaciones, con los híbridos invocando ambas herramientas.

Medición de aceptación del 2026-10-16, con el modelo definitivo (`gemini-3.1-flash-lite`), la **base real** y la **recuperación real** (embeddings de Gemini sobre los 44 fragmentos):

Medida	Resultado
Clasificación correcta	**12 de 13** (mínimo 11)
Híbridos que invocan ambas herramientas	3 de 3
Pregunta sin cobertura sin invocar herramientas	1 de 1
Clasificación emitida antes de las herramientas	12 de 13
Contenido correcto (SQL, RAG, híbridos y sin cobertura)	12 de 13 (5/5, 3/4, 3/3 y 1/1)
Sentencias SQL rechazadas por el validador	0 de 8
Consultas registradas en `agent_runs`	13 de 13
Casos en inglés (B1 y B2)	2 de 2, con respuesta en inglés

El único caso fallido (G9, el horario de la biblioteca) no se debió a una clasificación equivocada: el servicio de Gemini devolvió un error 503 por alta demanda durante la llamada del clasificador. Repetido solo, G9

clasificó `rag`, recuperó el reglamento y respondió bien. Las otras mediciones versionadas del modelo definitivo dieron 13 de 13 en la clasificación (corridas del 2026-10-10 y 2026-10-11). Las corridas con un modelo local sirven para validar el flujo y no cuentan como aceptación (R-2.8).

Latencia. En esta corrida, la mediana por consulta fue de 5,7 s y los casos sin cobertura o de una sola fuente tardaron entre 1,5 y 12,5 s. Los híbridos tardan más porque combinan varias llamadas (7 a 67 s). Los valores máximos de las corridas versionadas (por ejemplo 146 s en B2) corresponden a esperas de la API ante la cuota y los picos de demanda, no al cómputo del agente (ver `TP/05-validacion.md`, sección 4.1).

6.3 Calibración del umbral del RAG

El umbral se midió con 21 preguntas sobre los documentos reales: 15 con cobertura (similitud entre 0,646 y 0,802) y 6 sin cobertura (entre 0,597 y 0,649). Las dos poblaciones **se solapan** apenas, así que ningún valor las separa del todo. Se fijó **0,64**: es un filtro grueso, y la segunda barrera es el clasificador junto con la regla de declarar la ausencia de información cuando los fragmentos no responden.

6.4 Ejemplos de consultas

Los siguientes ejemplos salen de la tabla `agent_runs` de la corrida del 2026-10-16 (`TP/evidencia/agent_runs_2026-10-16.json`). Las fechas de los préstamos son relativas al día de carga del seed.

Consulta SQL. «¿Qué socios tienen préstamos vencidos?» (clasificación `sql`, 12,5 s).

```
SELECT DISTINCT s.nombre AS nombre, s.apellido AS apellido, v.dias_atraso AS dias_atraso
FROM v_prestamos_estado AS v JOIN socios AS s ON s.id = v.socio_id
WHERE v.estado_calculado = 'vencido' ORDER BY v.dias_atraso DESC
```

> Los socios que tienen préstamos vencidos son: Roberto Medina, con 15 días de atraso; Tomás Romero, con 11; Juan Pérez, con 6; Facundo Torres, con 4; Nicolás Gómez, con 2.

Fuente declarada: `sql`. El SQL usa la vista, porque el vencimiento no se guarda.

Consulta SQL con ranking. «¿Cuáles son los 5 libros más prestados este cuatrimestre?» El modelo usó el rango configurado (`BETWEEN '2026-08-01' AND '2026-11-30'`) y devolvió Clean Code (4 préstamos), Cien años de soledad (2), Artificial Intelligence: A Modern Approach (2), Computer Networks (1) y Calculus (1).

Consulta RAG. «¿Cuántos días tengo para devolver un libro antes de que me multen?» (clasificación `rag`, 5,7 s). Se recuperaron fragmentos de `reglamento_biblioteca.pdf` («Artículo 5. Multas por atraso», similitud 0,796; «Artículo 2. Plazos de préstamo», 0,742) y de `politicas_universidad.pdf`.

> El plazo depende de tu categoría como socio. Alumnos: 14 días corridos. Docentes: 30 días corridos. [...] Si el libro se devuelve después de esa fecha, se genera una multa por cada día de atraso.

Fuente declarada: `rag`. La interfaz muestra los fragmentos con su documento y ubicación.

Consulta híbrida. «¿Un docente tiene un plazo distinto que un alumno para el libro más prestado?» (clasificación `hybrid`, 35 s). El agente consultó la base para saber cuál es el libro más prestado y luego buscó la norma en el reglamento.

> El libro más prestado de la biblioteca es «Clean Code». Sí, los docentes y los alumnos tienen plazos distintos: los alumnos cuentan con 14 días corridos y los docentes con 30.

Fuentes declaradas: `sql` y `rag`.

Consulta en inglés. «How many days do I have to return a book before I get fined?» El agente respondió en inglés, a partir del mismo reglamento en castellano: «Students: the loan period is 14 consecutive days. Teachers: 30 consecutive days.»

Sin cobertura. «¿Cuál es el precio del libro “Rayuela”?» El modelo de datos no registra precios, así que el agente no inventa un valor y responde con un mensaje fijo: «Busqué en la base y en los documentos y no encontré nada sobre eso. Probá con otra pregunta o con el título exacto del libro.» No invocó ninguna herramienta (1,5 s) y `sources` quedó vacío.

Pedido de escritura. Una consulta que pide modificar datos no ejecuta ninguna herramienta ni llama al modelo para redactar; se responde con un mensaje fijo que explica que el agente es de solo lectura.

6.5 Registro de trazabilidad

Cada consulta deja una fila en `agent_runs`. Por ejemplo, la de «¿Qué libros tiene prestados el socio Juan Pérez?» registra: clasificación `sql`, herramienta `execute_sql`, la sentencia generada y la normalizada que corrió, el modelo (`gemini/gemini-3.1-flash-lite`), el endpoint `api`, estado `ok` y latencia de 7,4 s. El archivo `TP/evidencia/agent_runs_2026-10-16.json` contiene las 15 consultas de la corrida con todos esos campos.

6.6 Concurrencia

El agente atiende las consultas **en serie** (D77): cada una espera a que termine la anterior. La espera de la k-ésima consulta es (k−1) veces el tiempo de servicio. `scripts/measure_queue.py` lo mide sobre el agente real con un tiempo de servicio simulado: con 6 s y tres consultas simultáneas esperan 0, 6 y 12 s, y el cliente recibe latidos mientras espera. Es adecuado para un uso de pocas personas simultáneas, que es el alcance del trabajo.

7. Limitaciones del diseño

- **Alcance de solo lectura.** El agente no crea, modifica ni borra datos; lo declara cuando se le pide.
- **Un turno por consulta.** No recibe historial: la interfaz conserva la conversación solo en pantalla.
- **Umbral del RAG grueso.** Las similitudes de los casos con y sin cobertura se solapan; la ausencia de información se apoya además en el clasificador y en la regla de no responder con conocimiento propio.
- **Cuota de la API.** La latencia depende de la cuota de la API de Gemini y de sus picos de demanda (como el error 503 de G9); el sistema reintenta, pero una consulta puede tardar minutos.
- **Sin autenticación.** El servicio corre en entorno local; exponerlo públicamente exigiría control de acceso.
- **Cobertura documental.** El conocimiento del RAG se limita a los seis documentos incluidos.

8. Metodología: Spec Driven Development

El desarrollo siguió el ciclo `Requirement → Spec → Plan → Tasks → Implementation → Validation` con la herramienta OpenSpec. Todos los artefactos están versionados en el repositorio:

Artefacto	Ubicación
Constitución (11 artículos que no se rompen: proveniencia de las respuestas, trazabilidad, secretos fuera del código, etc.)	`TP/00-constitucion.md`
Especificación funcional y técnica	`TP/01-especificacion-funcional.md`, `TP/02-especificacion-tecnica.md`
Validación: casos de prueba, calibración y corridas medidas	`TP/05-validacion.md`, `TP/evidencia/`
Registro de decisiones, con fecha y motivo	`TP/CHANGELOG.md`
Cuatro changes de OpenSpec: requisitos con escenarios `GIVEN / WHEN / THEN`, diseño y tareas	`openspec/changes/` (`agente-y-tools`, `base-de-datos-neon`, `frontend-web-vite`, `frontend-markdown-answer`)

Cada requisito tiene un identificador (por ejemplo `R-3.4`), una decisión de diseño lleva el suyo (`D12`) y las pruebas citan ambos, de modo que se puede seguir un comportamiento desde el requisito hasta la prueba que lo verifica. La especificación se escribe antes que el código y `openspec validate --all --strict` valida que cada requisito tenga al menos un escenario.

9. Reproducción

El `README.md` contiene la guía exacta. En resumen: clonar el repositorio, copiar `.env.example` a `.env` y completar las credenciales y la `GEMINI_API_KEY`, y ejecutar `docker compose up -d --build --wait`. Se levantan la base con el seed y las extensiones, la ingesta de los PDF, la API y la interfaz en `http://localhost:3000`. Las pruebas se corren con `python -m pytest -q`, y la medición de aceptación con `python scripts/measure_golden.py --db --rag-real --bilingual`.